

PORTADA

Seguridad ciudadana en el Peru: identificacion de perfiles territoriales de criminalidad y clasificacion de contextos de alta victimizacion mediante Machine Learning

Curso: Machine Learning

Equipo: [Completar integrantes]

Institucion: [Completar]

Fecha: septiembre de 2026

RESUMEN EJECUTIVO

Este informe presenta un pipeline reproducible de Machine Learning aplicado a seguridad ciudadana en el Peru. Se integraron 369,100 registros de denuncias policiales, 1,592 filas ENAPRES y poblacion oficial proyectada. La unidad de analisis viable fue departamento-año, con 182 observaciones entre 2018 y 2024. El trabajo no busca predecir delitos individuales: busca describir patrones territoriales agregados, clasificar contextos de alta victimizacion relativa y discutir sus limites tecnicos, juridicos y eticos.

A. CONTEXTO DEL PROBLEMA

La seguridad ciudadana combina hechos registrados, experiencias de victimizacion, percepcion social de inseguridad y confianza institucional. Estos cuatro elementos no son equivalentes: una denuncia policial depende de que el hecho ocurra, sea reconocido como delito, sea denunciado y sea registrado; la victimizacion ENAPRES mide experiencia reportada en encuesta; la percepcion resume expectativas y temores; y la confianza refleja relacion con la PNP. Por ello, el valor academico del proyecto esta en analizar esas dimensiones de manera integrada, evitando conclusiones simplistas sobre criminalidad real.

B. COMPRENSION DEL NEGOCIO

La institucion usuaria hipotetica seria el Ministerio del Interior o un observatorio de seguridad ciudadana. La necesidad publica es contar con evidencia territorial para priorizar diagnosticos, comparar contextos y comunicar hallazgos de forma transparente. El producto esperado es un tablero explicativo y un modelo reproducible que apoyen la discusion tecnica. No se propone un sistema de vigilancia, scoring de personas ni asignacion automatica de recursos policiales.

C. COMPRENSION Y VALIDACION DE DATOS

La integracion se limito al nivel departamento-año porque esa es la granularidad comun validada entre las fuentes. Aunque SIDPOL contiene informacion mas detallada por fecha, distrito y modalidad, ENAPRES esta publicada para este recurso en agregados nacional/departamental/anual. Forzar una

union distrital habria multiplicado registros y creado precision falsa. El panel final cubre 26 jurisdicciones y no presenta duplicados departamento-anio.

D. ANALISIS EXPLORATORIO

Las denuncias totales agregadas disminuyeron en 2020 hasta 649,169, un comportamiento consistente con un periodo excepcional de movilidad y registro. Luego aumentaron hasta 1,044,843 en 2023 y se mantuvieron altas en 2024 con 1,014,315. En 2024, la victimizacion promedio departamental fue 24.5%, la percepcion de inseguridad 51.0% y la confianza en la PNP 17.7%. El EDA muestra que la percepcion puede permanecer elevada incluso cuando la victimizacion no crece en la misma magnitud, por eso se construyo la brecha percepcion-victimizacion como indicador interpretativo.

E. PLANTEAMIENTO DE MACHINE LEARNING

Se formularon dos tareas. La primera es no supervisada: identificar perfiles territoriales mediante clustering con variables de denuncias, victimizacion, percepcion y confianza. La segunda es supervisada: clasificar departamento-anio con alta victimizacion relativa, definida como estar en el percentil 75 de su anio. La definicion anual evita que un solo cambio temporal global distorsione el target y permite comparar territorios dentro de cada periodo.

F. IMPLEMENTACION DE MODELOS

Para clustering se compararon K-Means y clustering aglomerativo Ward con k entre 2 y 7, usando variables estandarizadas. Para clasificacion se compararon DummyClassifier, Regresion Logistica y Random Forest. La particion fue temporal: entrenamiento en 2019-2022 y prueba en 2023-2024. Esta decision es mas exigente que una division aleatoria porque simula el uso real del modelo sobre anios futuros.

G. RESULTADOS DEL CLUSTERING

La seleccion final fue KMeans con k=3. La separacion no es perfecta: el silhouette es moderado, lo cual es esperable en datos sociales agregados donde los territorios no se dividen en grupos totalmente puros. Aun asi, los perfiles son interpretables. Cluster 0: 41 observaciones, tasa media 2,509.7, victimizacion 26.8%, percepcion 54.0% y confianza 13.2%. Cluster 1: 61 observaciones, tasa media 1,877.5, victimizacion 17.5%, percepcion 31.6% y confianza 23.6%. Cluster 2: 59 observaciones, tasa media 2,861.8, victimizacion 21.0%, percepcion 56.0% y confianza 20.1%. Estos grupos deben leerse como perfiles analiticos, no como etiquetas permanentes ni como rankings de peligrosidad.

H. RESULTADOS DE CLASIFICACION

El baseline DummyClassifier obtuvo accuracy 0.761, pero precision, recall y F1 iguales a cero para la clase de alta victimizacion; por tanto, la accuracy aislada habria sido enganosa. Random Forest fue el

mejor modelo con accuracy 0.891, precision 0.688, recall 1.000, F1 0.815, ROC-AUC 1.000 y PR-AUC 1.000. El recall alto es importante porque reduce falsos negativos, es decir, casos de alta victimización que el sistema no detectaría. Sin embargo, la muestra de prueba es pequeña, por lo que las métricas deben actualizarse y validarse con nuevos años.

I. EXPLICABILIDAD

La importancia por permutación indicó que las variables con mayor aporte predictivo fueron: denuncias tasa 100k lag1 (0.032), percepción inseguridad pct lag1 (0.032), diversidad modalidades (0.022), denuncias total lag1 (0.018). Estas importancias no prueban causalidad. Indican que, dentro de este experimento, al alterar esas variables se deteriora el desempeño del modelo. La lectura correcta es técnica y prudente: los rezagos de denuncias y percepción ayudan a anticipar contextos de victimización alta relativa, pero no explican por sí solos por qué ocurre la inseguridad.

J. PERSPECTIVA JURÍDICA Y DE POLÍTICA PÚBLICA

Un modelo aplicado al Estado debe respetar legalidad, transparencia, proporcionalidad, calidad de datos, rendición de cuentas y supervisión humana. En el marco peruano son relevantes la Ley de Gobierno Digital, la Ley de Protección de Datos Personales y la Política Nacional Multisectorial de Seguridad Ciudadana al 2030. Aunque el panel usado es agregado y no contiene datos personales directos, sus resultados pueden afectar narrativas públicas sobre territorios; por eso se recomienda evitar lenguaje estigmatizante y documentar siempre las limitaciones.

K. INTELIGENCIA ARTIFICIAL RESPONSABLE

Los principales riesgos son sesgo de reporte, subregistro, diferencias territoriales en acceso a comisarias, cambios administrativos, sesgo de encuesta, ecological fallacy y automation bias. Las mitigaciones propuestas son: publicar diccionario de variables, mantener trazabilidad de fuentes, recalcular métricas con cada actualización, incluir revisión experta, monitorear desempeño por periodos, prohibir usos individuales y presentar el tablero como apoyo al análisis, no como veredicto automatizado.

CONCLUSIONES

El proyecto demuestra que es posible integrar datos oficiales para construir un diagnóstico territorial reproducible de seguridad ciudadana en el Perú. La decisión metodológica más importante fue trabajar en departamento-año para respetar la estructura real de las fuentes. El clustering aporta perfiles útiles para exploración y la clasificación muestra señales predictivas superiores al baseline. La principal advertencia es que las denuncias no son criminalidad real completa, y las salidas del modelo deben usarse siempre con interpretación humana y contexto institucional.

RECOMENDACIONES

Actualizar el pipeline cuando MININTER e INEI publiquen nuevos cortes, incorporar covariables oficiales solo si comparten granularidad, revisar el umbral de alta victimizacion con especialistas, agregar intervalos de incertidumbre cuando sea posible y complementar el tablero con lectura cualitativa territorial. Para exposicion, se recomienda enfatizar que el proyecto combina rigor tecnico con prudencia publica: modela patrones agregados, no personas.

REFERENCIAS IEEE

Referencias IEEE

[1] Ministerio del Interior, "Denuncias Policiales," Plataforma Nacional de Datos Abiertos, dataset y recursos CSV/XLSX/DOCX, actualizado el 10 de septiembre de 2026. [En línea]. Disponible: <https://www.datosabiertos.gob.pe/dataset/denuncias-policiales-1>. [Consultado: 11-sep-2026].

[2] Ministerio del Interior, "Victimización, Percepción de Inseguridad y Confianza en la PNP," Plataforma Nacional de Datos Abiertos, dataset y recursos CSV/XLSX/DOCX, actualizado el 10 de septiembre de 2026. [En línea]. Disponible: <https://www.datosabiertos.gob.pe/dataset/victimizaci%C3%B3n-percepci%C3%B3n-de-inseguridad-y-confianza-en-la-pnp>. [Consultado: 11-sep-2026].

[3] Instituto Nacional de Estadística e Informática, "Perú: Población Total Proyectada al 30 de Junio de cada año, según Departamento, Provincia y Distrito, 2018-2026," Plataforma del Estado Peruano, 31 de diciembre de 2025. [En línea]. Disponible: <https://www.gob.pe/institucion/inei/informes-publicaciones/6894980-peru-poblacion-total-proyectada-al-30-de-junio-de-cada-ano-segun-departamento-provincia-y-distrito-2018-2026>. [Consultado: 11-sep-2026].

[4] Ministerio del Interior, "Política Nacional Multisectorial de Seguridad Ciudadana al 2030," Plataforma del Estado Peruano, 23 de junio de 2022. [En línea]. Disponible: <https://www.gob.pe/institucion/mininter/informes-publicaciones/3150919-politica-nacional-multisectorial-de-seguridad-ciudadana-al-2030>. [Consultado: 11-sep-2026].

[5] Presidencia del Consejo de Ministros, "Decreto Legislativo N.º 1412: Ley de Gobierno Digital," Plataforma del Estado Peruano, 13 de septiembre de 2018. [En línea]. Disponible: <https://www.gob.pe/institucion/pcm/normas-legales/289706-1412>. [Consultado: 11-sep-2026].

[6] Congreso de la República del Perú, "Ley N.º 29733: Ley de Protección de Datos Personales," Plataforma del Estado Peruano, 3 de julio de 2011. [En línea]. Disponible: <https://www.gob.pe/institucion/congreso-de-la-republica/normas-legales/243470-29733>. [Consultado: 11-sep-2026].

modelo	accuracy	precision	recall	f1
DummyClassifier	0.761	0.0	0.0	0.0

modelo	accuracy	precision	recall	f1
LogisticRegression	0.522	0.333	1.0	0.5
RandomForest	0.891	0.688	1.0	0.815

Figura 1. Evolucion anual de denuncias.




Figura 2. Victimizacion y percepcion.




Figura 3. Clusters territoriales.




Figura 4. Importancia predictiva.

